



# Epidémiologie et Biostatistique sur un Entrepôt de Données hospitalier

02 juin 2026

Introduction à l'appariement des bases

Luca THIEBAUD & Adam REMAKI

[luca.thiebaud@centralesupelec.fr](mailto:luca.thiebaud@centralesupelec.fr)

[adam.remaki@centralesupelec.fr](mailto:adam.remaki@centralesupelec.fr)

## L'appariement (*record linkage*):

*Déf: tâche consistant à trouver des données qui se réfèrent à la même entité à travers différentes sources de données.*

### Objectif:

- Lier deux bases de données de **source différente** en comparant des paires de records
- Dédupliquer un identifiant censé être unique d'une base de données

### L'appariement déterministe:

- Utilisation d'identifiants: variables communes aux deux bases de données
- Match si accord sur les identifiants (cas trivial: jointure sur une clé)
- Processus possiblement itératif match sur IPP → **si absent** match sur NIR  
→ **si absent** match exact sur (prénom, nom, date de naissance)

Un appariement déterministe peut avoir différents niveaux de *confiance*

### L'appariement probabiliste:

- Introduction d'une **probabilité de match** et d'une **frontière de décision**
- Article princeps de Fellegi et al. [1]

[1] Fellegi I, Sunter A. A theory for record linkage. J Am Stat Assoc. 1969;64.

## International Journal of Population Data Science

Journal Website: [www.ijpds.org](http://www.ijpds.org)



### Demystifying probabilistic linkage: Common myths and misconceptions

Doidge, JC<sup>1,2\*</sup> and Harron, K<sup>3</sup>

- **Méthodes probabiliste et déterministes sont différentes ?**
  - Pas forcément, on a équivalence entre trouver un ensemble de règles de décisions déterministes et trouver des ensembles (poids / threshold) dans un contexte probabiliste
- **Méthodes probabilistes basées sur la “probabilité qu’une paire soit un match” ?**
  - En réalité, les poids sont des scores censés être en corrélation avec cette probabilité qu’une paire soit un match, mais la probabilité exacte est souvent inconnue.
- **Les méthodes probabilistes induisent plus d’erreurs ?**
  - Réduisent en général la précision, mais augmentent ainsi le rappel

*Précision = nombre de bons matches prédits / nombre total de matches prédits (bons ou mauvais)*

*Rappel = nombre de bons matches prédits / nombre total de bons matches*

**La précision** peut être comprise comme une mesure de l’exactitude ou de la qualité.

**le rappel** est une mesure de l’exhaustivité ou de la quantité.

- 2 ensembles A et B: on travaille sur  $A \times B$ , qui est l'union de 2 sous-ensembles disjoints:
  - M : sous ensemble des matches de  $A \times B$
  - U : sous ensemble des non-matches de  $A \times B$
- Pour une paire issue de  $A \times B$ :
  - construction d'un **vecteur de comparaison** (one-hot encoding) en fonction de la concordance ou non sur **K** variables communes
  - Le modèle estime ensuite le **poids** de chaque variable, en supposant leur indépendance (Naive Bayes)

|             |       |            |       |
|-------------|-------|------------|-------|
| Michel      | SCOTT | 13-10-1950 | PARIS |
| Jean-Michel | SCOTT | 13-10-1950 | PARIS |
| 0           | 1     | 1          | 1     |

$$\gamma = [0, 1, 1, 1]$$

**But: estimer**  $\Pr(\text{record match} \mid \gamma)$

- **m-probabilities et u-probabilities :**

- Intuition:

- Si une variable match, soit la paire match, soit on a une **collision** → On compare  $m_{i,1}$  vs  $u_{i,1}$
- Si une variable ne matche pas, soit la paire matche (typo, différence de format, ...), soit la paire ne matche pas non plus → on compare  $m_{i,0}$  vs  $u_{i,0}$

- Formalisation → Introduction du **Bayes Factor**

- **m-probabilities et u-probabilities :**

$m_{i,1} = \Pr(\text{variable } i \text{ matches} \mid \text{records match})$

$m_{i,0} = \Pr(\text{variable } i \text{ mismatches} \mid \text{records match})$

$u_{i,1} = \Pr(\text{variable } i \text{ matches} \mid \text{records do not match})$

$u_{i,0} = \Pr(\text{variable } i \text{ mismatches} \mid \text{records do not match})$

- Intuition:

- Si une variable match, soit la paire match, soit on a une **collision** → On compare  $m_{i,1}$  vs  $u_{i,1}$
- Si une variable ne matche pas, soit la paire matche (typo, différence de format, ...), soit la paire ne matche pas non plus → on compare  $m_{i,0}$  vs  $u_{i,0}$

- Formalisation → Introduction du **Bayes Factor**

$$b_{i,1} = \frac{m_{i,1}}{u_{i,1}}$$

$$b_{i,0} = \frac{m_{i,0}}{u_{i,0}}$$

- Pour une variable  $i$ , calcul de la probabilité à postérieure (*posterior*)
- Pour le vecteur de comparaison  $\gamma$

- Pour une variable  $i$ , calcul de la probabilité à postériori (*posterior*)

$$\begin{aligned}\Pr(\text{records match} \mid \gamma_i) &= \frac{\Pr(\gamma_i \mid \text{records match}) \Pr(\text{records match})}{\Pr(\gamma_i)} \\ &= \frac{m_{i,l}\lambda}{m_{i,l}\lambda + u_{i,l}(1 - \lambda)}\end{aligned}$$

$$\text{with } \begin{cases} \lambda = \Pr(\text{records match}) \\ l = 0 \text{ if } \gamma_i = 0 \\ l = 1 \text{ if } \gamma_i = 1 \end{cases}$$

- Pour le vecteur de comparaison  $\gamma$



- Pour une variable  $i$ , calcul de la probabilité à postériori (*posterior*)

$$\begin{aligned}\Pr(\text{records match} \mid \gamma_i) &= \frac{\Pr(\gamma_i \mid \text{records match}) \Pr(\text{records match})}{\Pr(\gamma_i)} \\ &= \frac{m_{i,l}\lambda}{m_{i,l}\lambda + u_{i,l}(1 - \lambda)}\end{aligned}$$

with  $\begin{cases} \lambda = \Pr(\text{records match}) \\ l = 0 \text{ if } \gamma_i = 0 \\ l = 1 \text{ if } \gamma_i = 1 \end{cases}$

- Pour le vecteur de comparaison  $\gamma$

$$\begin{aligned}\Pr(\text{records match} \mid \gamma) &= \Pr(\text{records match} \mid \gamma_1, \dots, \gamma_K) \\ &= \frac{\prod_{i=1}^K \Pr(\gamma_i \mid \text{records match}) \cdot \Pr(\text{records match})}{\Pr(\gamma_1, \dots, \gamma_K)} \quad \text{par indépendance} \\ &= \frac{\lambda m_{1,l} \cdot m_{2,l} \dots m_{K,l}}{\lambda m_{1,l} \cdot m_{2,l} \dots m_{K,l} + (1 - \lambda) u_{1,l} \cdot u_{2,l} \dots u_{K,l}}\end{aligned}$$

- En terme de cote



- En terme de cote

$$\begin{aligned} \text{odds} &= \frac{p}{1-p} \\ &= \frac{\lambda}{1-\lambda} \cdot \frac{\prod m_{i,l}}{\prod u_{i,l}} \\ &= \frac{\lambda}{1-\lambda} \cdot b_{1,l} \dots b_{K,l} \end{aligned}$$

- En terme de cote


$$\begin{aligned} \text{odds} &= \frac{p}{1-p} \\ &= \frac{\lambda}{1-\lambda} \cdot \frac{\prod m_{i,l}}{\prod u_{i,l}} \\ &= \frac{\lambda}{1-\lambda} \cdot b_{1,l} \dots b_{K,l} \end{aligned}$$

$$\log_2(\text{odds}) = \log_2\left(\frac{\lambda}{1-\lambda}\right) + \log_2(b_{1,l}) + \dots + \log_2(b_{K,l})$$

- En terme de cote

$$\begin{aligned} \text{odds} &= \frac{p}{1-p} \\ &= \frac{\lambda}{1-\lambda} \cdot \frac{\prod m_{i,l}}{\prod u_{i,l}} \\ &= \frac{\lambda}{1-\lambda} \cdot b_{1,l} \dots b_{K,l} \end{aligned}$$

- Construction itérative de la probabilité de match:




$$\log_2(\text{odds}) = \log_2\left(\frac{\lambda}{1-\lambda}\right) + \log_2(b_{1,l}) + \dots + \log_2(b_{K,l})$$

- L'idée générale du modèle est donc d'utiliser une **estimation du poids relatif de chaque variable** :

|                   | m    | u     | b   |
|-------------------|------|-------|-----|
| Date de naissance | 0.95 | 0.001 | 950 |
| Nom               | 0.9  | 0.01  | 90  |
| Sexe              | 0.95 | 0.5   | 1.9 |

- Limites:
  - Concordance binaire
  - Indépendance des variables
  - Comment estimer m et u ? → Empiriquement ou bien via un algorithme EM
- A retenir:
  - **Certaines variables ont un poids (bien) plus importants pour déterminer le statut d'une paire**
  - **Variable clé:** Date de naissance
  - Nécessité d'une étape de **blocking**: présélectionner des candidats pour limiter le nombre de comparaisons

- Cas d'usage: déduplication d'une base de  $N = 10M$  de patients



- Approche naïve: comparaison complète
  - $N^2$  paires de patient → **100 milliards ici**
  - Il faut présélectionner des **candidats**



- *Standard Blocking*: utilisation d'une *clé*
  - Par exemple: initiale du nom, année de naissance
  - Avec  $b$  blocs, le nombre de comparaisons est alors en  $\mathcal{O}\left(\frac{N^2}{b}\right)$
  - **Attention à la taille des blocs**
  - **Attention au choix de la clé**




- Le choix d'une technique de blocking adaptée est **essentiel**
- 2 métriques classiques pour mesurer la qualité du blocking:
  - **Pairs Completeness:**  $PC = \frac{Card(\text{matches détectés})}{Card(\text{matches existants})}$
  - **Pairs Quality:**  $PQ = \frac{Card(\text{matches détectés})}{Card(\text{bloc})}$
- Tradeoff entre
  - Optimisation du temps de calcul
  - Optimisation de la procédure d'appariement



- En sortie d'algorithme, on a un ensemble de paires de matches
- De cet ensemble, il est possible de créer un graphe
  - Les noeuds sont les patients
  - Les arêtes déterminent si 2 patients sont appariés
- On en retire alors les **composantes connexes**

|   |   |
|---|---|
| A | B |
| A | C |
| B | D |
| E | F |

*Paires de matches*





*Composantes connexes*


# Un exemple d'algorithme: Déduplication des patients de l'EDS

- But de l'algorithme:
  - Proposer un 1ère version d'un algorithme de dédoublenage moins conservateur que le l'algorithme existant (destiné au soin) à destination de la recherche
  - Doit tourner sur les ~13M de patients de l'EDS en un temps court / avec des ressources raisonnables
- Fonctionnement global
  - Utilisation des variables avec une complétude élevée
  - Blocking sur la date de naissance
    - On passe de  $6.4 \times 10^{13}$  à  $2.2 \times 10^9$  comparaisons
  - Fuzzy-matching sur les patronymes
    - Métrique de **Jaro-Winkler**
    - Détermination du threshold via une campagne d'annotation

| Colonne     | Entrées non-nulles (%) |
|-------------|------------------------|
| 1 nom       | 99.999373              |
| 0 prenom    | 99.994017              |
| 5 dt_nais   | 91.531307              |
| 3 cd_genre  | 90.703285              |
| 2 nom_nais  | 65.168952              |
| 4 lieu_nais | 20.267825              |



- Exemple de biais identifié sur les dates de naissance
  - Sur-représentation du 1er Janvier et 31 décembre
    - Origine identifiée
      - 1er Janvier: attribuée par défaut par l'état civil en l'absence de date précise
      - 31 décembre: attribuée par défaut à l'arrivée à l'AP-HP si absence de papiers
  - Sur-représentation des décennies
  - Cause de FP importante, visible dans les “grands” composants:



- Gestion des valeurs manquantes
  - Approches classiques:
    - éliminer les patients avec au moins 1 valeur manquante du processus d'appariement
    - Considérer qu'une valeur manquante correspond à un match exact sur cette valeur
    - Considérer qu'une valeur manquante correspond à un non-match total sur cette valeur
  - ML et DL
    - Peu de recherche à ce niveau !
    - Pourtant, [1] montre qu'un simple MLP est meilleur que le Naive Bayes présenté précédemment.
    - Dans le futur, usage d'embeddings et de réseaux siamois [2] ?

[1] Wilson et al, Beyond probabilistic record linkage: Using neural networks and complex features to improve genealogical record linkage


[2] Anna Jurek-Loughrey; (2020). Siamese Neural Network for Unstructured Data Linkage



## Exercice 2 – Déduplication des identités

- Pull le sujet de l'exercice 2 depuis le repo GitHub
- Ouvrir le notebook `exercises/exercise-2`
  - Contexte :
    - Mise à disposition d'une table de déduplication déterministe pour les patients
    - Mise à disposition d'une table de déduplication probabiliste pour les patients
  - Objectif : Comparer l'impact de la déduplication sur les résultats

## Schéma de la base mise à disposition





# Projet



## ■ Question scientifique

- Identification des facteurs de risque associés au cancer du sein
- Analyse rétrospective à partir des données de l'EDS

## ■ Objectifs globaux

- Synthèse de la littérature sur le sujet
- Construction des objectifs techniques pour répondre à la question scientifique
- Nettoyage/Traitement de la BDD mise à disposition
- Analyses statistiques
- Restitution
  - *Court article scientifique (~1500 mots)*
  - *Notebook reproductible*

## ■ Objectifs première journée

- Lecture de la base
- Exploration & mapping des données
- Revue documentaire (introduction de l'article scientifique)
- Elaboration d'un patient set et des facteurs de risques à évaluer

## ■ Objectifs seconde journée

- Implémenter la déduplication du patient set
- Analyse comparative des premiers facteurs de risques

## ■ Bibliographie

- Kohane, Isaac S, Bruce J Aronow, Paul Avillach, Brett K Beaulieu-Jones, Riccardo Bellazzi, Robert L Bradford, Gabriel A Brat, et al. « What Every Reader Should Know About Studies Using Electronic Health Record Data but May Be Afraid to Ask ». *Journal of Medical Internet Research* 23, n° 3 (2 mars 2021): e22219. <https://doi.org/10.2196/22219>.
- Agniel, Denis, Isaac S Kohane, et Griffin M Weber. « Biases in Electronic Health Record Data Due to Processes within the Healthcare System: Retrospective Observational Study ». *BMJ*, 30 avril 2018, k1479. <https://doi.org/10.1136/bmj.k1479>.
- Wilson, Greg, D. A. Aruliah, C. Titus Brown, Neil P. Chue Hong, Matt Davis, Richard T. Guy, Steven H. D. Haddock, et al. « Best Practices for Scientific Computing ». Édité par Jonathan A. Eisen. *PLoS Biology* 12, n° 1 (7 janvier 2014): e1001745. <https://doi.org/10.1371/journal.pbio.1001745>.
- Benchimol, Eric I., Liam Smeeth, Astrid Guttman, Katie Harron, David Moher, Irene Petersen, Henrik T. Sørensen, Erik von Elm, Sinéad M. Langan, et RECORD Working Committee. « The REporting of Studies Conducted Using Observational Routinely-Collected Health Data (RECORD) Statement ». *PLOS Medicine* 12, n° 10 (6 octobre 2015): e1001885. <https://doi.org/10.1371/journal.pmed.1001885>.